

Analisis Label Nutrisi Bertahap pada Minuman Kemasan Menggunakan YOLOv8, OCR, dan SVM untuk Perkiraan Kesehatan dan Risiko

Firji Achmad Fahresi, Muh Faqih S Musgamy, Andi Baso Kaswar*, Muhammad Fajar B, Dyah Darma Andayani, Muliadi, Jumadi Mabe Parenreng

Departemen Informatika dan Ilmu Komputer, Fakultas Teknik, Universitas Negeri Makassar, Makassar, Indonesia.

Diterima 15 Juni 20xx; diterima dalam bentuk revisi 05 Agustus 20xx; diterima 10 September 20xx

Abstrak

Konsumsi minuman kemasan yang tinggi gula, lemak jenuh, dan natrium mendorong prevalensi penyakit tidak menular (PTM). Namun, label nutrisi seringkali sulit dipahami oleh konsumen. Studi ini mengembangkan sistem cerdas menggunakan visi komputer dan kecerdasan buatan untuk mengevaluasi status kesehatan minuman kemasan. Pipeline ini mengintegrasikan YOLOv8 untuk deteksi label nutrisi, pra-pemrosesan gambar, Tesseract v5 OCR untuk ekstraksi teks, pembersihan hasil, klasifikasi kesehatan berbasis SVM, dan pemetaan risiko penyakit berdasarkan ambang batas nutrisi. YOLOv8 mencapai akurasi ($mAP@0.5$) 0,969, presisi (precision) 0,97, recall 0,88, dan skor F1 0,93 dengan waktu komputasi 7,014 detik. Pemrosesan pra-pengolahan secara efektif meminimalkan kesalahan OCR, sementara klasifikasi SVM yang dioptimalkan mencapai akurasi 99,86% menggunakan GridSearchCV dan penyeimbangan SMOTE. Sistem secara otomatis mengidentifikasi risiko penyakit potensial ketika tingkat nutrisi melebihi batas aman, menawarkan alat cepat dan akurat untuk mendukung keputusan konsumsi minuman yang lebih sehat.

Kata kunci: Penglihatan Komputer, YOLOv8, Pra-pemrosesan Gambar, Informasi Gizi, Risiko Penyakit Tidak Menular.

1. Pengantar

Minuman kemasan adalah jenis minuman yang telah melalui proses pengolahan dan pengemasan untuk memperpanjang masa simpan, seringkali dengan penambahan gula sederhana yang meningkatkan tingkat energi tanpa memberikan nilai gizi yang signifikan [1]. Popularitas produk-produk ini terus meningkat dalam beberapa tahun terakhir, sejalan dengan perubahan pola konsumsi masyarakat yang mengutamakan kemudahan. Namun, banyak produk kemasan mengandung kadar gula, garam, dan lemak yang tinggi, yang dapat meningkatkan risiko penyakit tidak menular (PTM) seperti diabetes, hipertensi, dan penyakit kardiovaskular [2], [3]. Dampak negatif ini lebih signifikan di kalangan remaja, yang lebih rentan terhadap pola makan tidak sehat akibat daya beli yang tinggi dan kebiasaan membaca label nutrisi yang rendah [4]. Selain itu, konsumsi sayur dan buah yang rendah di kalangan remaja juga memperburuk risiko NCD akibat konsumsi produk kemasan yang tidak sehat [5].

Tren konsumsi tidak sehat ini merupakan bagian dari fenomena global yang ditandai dengan peningkatan prevalensi obesitas. WHO (2024) melaporkan bahwa prevalensi obesitas global meningkat dari 12,1% pada 2012 menjadi 15,8% pada 2022, dengan tren serupa pada anak di bawah lima tahun, di mana tingkat kelebihan berat badan mencapai 5,6% pada 2022, dan WHO memperkirakan akan meningkat menjadi 5,7% pada 2030 [6]. Peningkatan ini tidak hanya terjadi di negara-negara maju tetapi juga di negara-negara berkembang, di mana konsumsi makanan olahan tinggi gula, garam, dan lemak semakin mendominasi pola makan masyarakat.

Di Indonesia, para peneliti mengamati tren serupa dalam peningkatan konsumsi minuman kemasan manis (SSBs). Kementerian Kesehatan Indonesia (2024) mencatat bahwa konsumsi MBDK di Indonesia merupakan yang tertinggi di kawasan Asia Pasifik, dengan kandungan gula rata-rata 22,8 gram per 250 ml, setara dengan 45,6% dari batas konsumsi harian yang direkomendasikan [7]. Survei Kesehatan Indonesia (IHS) 2023 juga menunjukkan bahwa 47,5% populasi mengonsumsi minuman manis lebih dari sekali sehari, meningkatkan risiko diabetes, obesitas, dan penyakit kardiovaskular [8]. Meskipun informasi gizi tersedia pada kemasan, banyak konsumen masih kesulitan memahami komposisi gizi dan dampaknya terhadap kesehatan. Selain itu, faktor sosial dan budaya mempengaruhi pola konsumsi ini, di mana minuman manis sering dikaitkan dengan gaya hidup modern dan kebiasaan bersosialisasi. Untuk mengurangi dampak negatif konsumsi minuman manis, peneliti dan pembuat kebijakan harus mengadopsi solusi berbasis teknologi yang secara otomatis mendeteksi kandungan gizi, menilai tingkat gula, garam, dan lemak secara real-time, serta menganalisis risiko penyakit potensial. Teknologi penglihatan komputer dan pembelajaran mesin dapat memainkan peran kunci dengan memindai kemasan, mengenali komponen nutrisi berisiko tinggi, dan memberikan peringatan dini kepada konsumen. Pendekatan ini tidak hanya membantu orang memahami komposisi nutrisi, tetapi juga berpotensi mengurangi beban penyakit tidak menular melalui pendidikan konsumsi yang lebih cerdas dan didasarkan pada fakta.

Dalam beberapa tahun terakhir, beberapa studi telah membahas masalah deteksi kesehatan pada makanan dan minuman kemasan menggunakan teknologi penglihatan komputer dan kecerdasan buatan. Banyak studi sebelumnya berfokus pada penerapan YOLO dalam mendeteksi area label, Pengenalan Karakter Optik (OCR), dan berbagai metode lain dalam mengekstrak informasi dari kemasan produk, serta menganalisis kandungan nutrisi menggunakan model kecerdasan buatan. Misalnya, sebuah studi mengusulkan metode berbasis Jaringan Konvolusional Penuh (FCN) dan Jaringan Neural Rekurens Konvolusional (CRNN) untuk mendeteksi area tanggal kadaluwarsa dan mengenali karakter teks secara otomatis. Model FCN mencapai akurasi deteksi 98,2% pada iterasi ke-100.000, sementara model CRNN mencapai akurasi pengenalan karakter 95,44% pada iterasi yang sama. Namun, pendekatan ini masih memiliki keterbatasan dalam menangani teks yang sangat buram atau tidak terbaca, serta memerlukan komputasi tinggi untuk proses pelatihan [9]. Selain itu, studi lain mengusulkan kerangka kerja berbasis Jaringan Konvolusional Penuh (FCN) untuk mengatasi kesulitan dalam mengenali tanggal kadaluwarsa pada produk kemasan akibat berbagai format tanggal dan kondisi pencetakan yang berbeda. Model tersebut mampu mengenali 13 format tanggal yang berbeda, dengan akurasi deteksi 98,31%, dan waktu eksekusi hanya 120 ms per gambar menggunakan NVIDIA RTX 2080 Ti. Namun, model tersebut masih mengalami kesalahan dalam kasus pantulan cahaya ekstrem atau tanggal yang sangat buram [10].

Selain itu, studi lain mengembangkan Nutrition5k, kumpulan 5.066 gambar hidangan kantin Barat lengkap dengan anotasi kalori dan makronutrien; model CNN yang dilatih pada dataset ini meningkatkan akurasi perkiraan kalori sekitar 16,5 persen dibandingkan metode konvensional, sehingga memberikan dasar yang kuat untuk aplikasi pencatatan nutrisi otomatis. Namun, cakupannya masih terbatas pada menu Barat dan belum mencakup produk minuman kemasan [11]. Selain itu, Program Informasi Label Makanan (FLIP) 2020, sebuah basis data yang berisi 74.445 produk makanan dan minuman dari tujuh pengecer daring Kanada, secara otomatis mengekstrak informasi label melalui web-scraping dan memvalidasi data tersebut dengan AI-OCR hingga akurasi 95 persen, sehingga berguna untuk memantau reformulasi nutrisi nasional. Namun, cakupannya masih terbatas pada saluran e-grocery dan belum mencakup produk pasar tradisional atau restoran [12].

Selain itu, sebuah studi meningkatkan DBNet dengan Modul Perhatian Blok Konvolusional untuk membaca tanggal kadaluwarsa pada kemasan; pendekatan ini mencapai akurasi deteksi karakter 97,9% dan kecepatan inferensi dua kali lipat dibandingkan CRNN pada Jetson Nano, meskipun kinerjanya masih terpengaruh oleh kualitas cetakan dan ukuran dataset yang terbatas [13]. Studi lain menerapkan transfer learning Inception v3 untuk mengklasifikasikan gambar makanan dan

menggabungkannya dengan crawler web Scrappy dan Selenium untuk mengumpulkan resep, asal, dan nilai gizi dari berbagai situs; model ini mencapai akurasi 97% dan skor F1 0,99 pada 20 kelas Food-101, tetapi kinerjanya menurun saat jumlah kelas diperluas dan pengumpulan data dibatasi oleh batasan akses situs [14].

Studi terpisah mengembangkan sistem berbasis deep learning menggunakan YOLOv7 untuk pengenalan gambar kemasan produk makanan guna menyediakan informasi keamanan pangan secara real-time melalui aplikasi seluler. Model YOLOv7 mencapai presisi 99,23% (), recall 100%, dan skor F1 99,46%, namun masih menghadapi keterbatasan dalam mengenali produk yang tidak termasuk dalam dataset pelatihan [15].

Selain sistem pemantauan keamanan pangan, studi lain mengusulkan NutrifyAI, platform berbasis AI untuk deteksi makanan, analisis nutrisi, dan rekomendasi diet yang dipersonalisasi. Model ini menggunakan YOLOv8 untuk deteksi makanan secara real-time, mencapai akurasi deteksi 75,4%, presisi 78,5%, recall 72,8%, dan skor F1 75,5%, namun tetap menghadapi tantangan dalam membedakan makanan dengan penampilan serupa [16].

Selain itu, sebuah studi menerapkan OCR berbasis Tesseract yang dikombinasikan dengan Model Bahasa Besar untuk mengekstrak teks label nutrisi dan menilai dampak kesehatan setiap bahan secara real-time; sistem ini mencapai akurasi analisis kesehatan 85% dan OCR 95%, namun masih bergantung pada kualitas cetakan dan tidak sepenuhnya mengaitkan nutrisi dengan risiko penyakit spesifik [17]. Di sisi lain, Borade dkk. menggabungkan OCR Tesseract, pola regex, dan NLP untuk mengidentifikasi alergen pada 10.000 label makanan dan merekomendasikan produk pengganti melalui kesamaan kosinus; solusi ini mencatat akurasi deteksi 90-95% dan akurasi rekomendasi 86%, namun kinerjanya menurun pada label yang buram dan istilah teknis yang bervariasi [18].

Selain itu, studi lain mengembangkan sistem berbasis YOLOv5 yang dikombinasikan dengan OCR dan metode klasifikasi berbasis aturan untuk mendeteksi status halal produk kemasan. Sistem ini mencapai akurasi klasifikasi 98%, tetapi masih bergantung pada basis data sertifikasi halal yang tersedia, dan belum mampu menangani produk dengan komposisi kompleks yang sulit diklasifikasikan secara otomatis [19]. Selain itu, studi lain mengembangkan metode berbasis AI yang menggabungkan deteksi objek untuk mengenali tanda sertifikasi dan OCR untuk mengekstrak teks terkait nutrisi dan kesehatan dari kemasan depan produk makanan bayi. Model ini mencapai akurasi deteksi tanda sertifikasi sebesar 94,9%, namun masih memiliki keterbatasan dalam memverifikasi klaim kesehatan yang digunakan dalam pemasaran produk bayi [20].

Selanjutnya, pendekatan dalam ekstraksi informasi label makanan berbasis AI mengembangkan Jaringan Saraf Konvolusional Rekurens (CRNN) yang dikombinasikan dengan OCR. Model ini mencapai akurasi 47,06% setelah 10 epoch, dengan potensi perbaikan lebih lanjut melalui optimasi model. Namun, metode ini masih menghadapi tantangan dalam menangani teks yang kompleks dan bervariasi, serta memerlukan perbaikan kualitas dataset dan optimasi model lebih lanjut [21].

Akhirnya, studi terbaru mengusulkan sistem pemindai cerdas yang dapat mengidentifikasi komposisi makanan dan minuman kemasan serta memberikan analisis nutrisi berbasis AI. Sistem ini menggunakan Google Vision API untuk OCR, dengan akurasi ekstraksi teks 87,88%, lebih tinggi daripada EasyOCR (83,11%) dan Tesseract OCR (79,05%). Model klasifikasi bahan makanan dalam studi ini mencapai akurasi 84%, dengan sensitivitas 85% dan spesifisitas 82%, namun masih memiliki keterbatasan dalam mengenali bahan makanan dengan nama non-standar dan memerlukan perbaikan pada kategori bahan berisiko tinggi untuk memberikan hasil analisis yang lebih akurat [22].

Namun, hingga saat ini, belum ada penelitian yang secara khusus mengintegrasikan deteksi label nutrisi, ekstraksi teks nutrisi menjadi data numerik, pengaturan ambang batas per porsi, dan pemetaan risiko penyakit tidak menular dalam satu alur otomatis menggunakan pendekatan visi komputer dan pembelajaran mesin. Sebagian besar studi berhenti pada deteksi area


label dan ekstraksi teks, tetapi tidak banyak yang melanjutkan ke tahap klasifikasi produk makanan. Akibatnya, studi sebelumnya belum sepenuhnya menampilkan hubungan antara kandungan gula, garam, lemak, dan kalori dengan risiko kesehatan, sehingga diperlukan pendekatan komprehensif untuk memberikan analisis risiko kesehatan yang akurat dan mudah dipahami bagi konsumen. Oleh karena itu, penelitian ini mengusulkan “Analisis Label Nutrisi Bertahap pada Minuman Kemasan Menggunakan YOLOv8, OCR, dan SVM untuk Perkiraan Kesehatan dan Risiko”, yang bertujuan untuk memberikan solusi atas masalah penilaian kualitas kesehatan minuman kemasan secara otomatis dengan pendekatan yang lebih komprehensif, yang tidak hanya mengandalkan OCR untuk ekstraksi informasi tetapi juga mengintegrasikan analisis nutrisi dengan risiko penyakit potensial menggunakan teknologi *pembelajaran mesin*.

Untuk mencapai tujuan ini, penelitian ini mengusulkan sistem berbasis *penglihatan komputer* dan kecerdasan buatan yang terdiri dari beberapa tahap utama, yaitu deteksi objek minuman kemasan menggunakan *YOLOv8*, ekstraksi informasi nutrisi menggunakan *Pengenalan Karakter Optik* (OCR), klasifikasi tingkat kesehatan menggunakan *Mesin Vektor Dukungan* (SVM), dan pemetaan risiko kesehatan potensial dengan mempertimbangkan faktor-faktor kunci seperti kalori, gula, garam, dan lemak.

Metode yang diusulkan bertujuan untuk memberikan akurasi tinggi dalam deteksi dan klasifikasi minuman kemasan, serta memetakan risiko kesehatan dengan tingkat presisi optimal. Dengan pencapaian ini, sistem yang dikembangkan bertujuan untuk membantu masyarakat dalam menilai kualitas kesehatan minuman kemasan secara otomatis, meningkatkan kesadaran akan pola konsumsi yang lebih sehat, dan mengurangi ketergantungan pada metode manual seperti membaca label komposisi atau berkonsultasi dengan ahli gizi. Selain itu, penelitian ini bertujuan untuk berkontribusi pada pengembangan teknologi penglihatan komputer di bidang makanan dan kesehatan, serta menjadi acuan bagi industri dalam menciptakan produk yang lebih sehat yang sesuai dengan standar gizi yang lebih baik.

2. Metode Penelitian

Penelitian ini dilakukan dalam beberapa tahap untuk mendeteksi kandungan nutrisi minuman kemasan dan memetakan risiko penyakit yang mungkin timbul akibat konsumsi berlebihan produk-produk tersebut, seperti yang ditunjukkan pada Gambar 1.



Gambar 1 Diagram metode deteksi kesehatan untuk minuman kemasan

2.1. Pengumpulan dataset

Pada tahap ini, penelitian memperoleh dataset yang terdiri dari sekitar 1.457 gambar label nutrisi produk minuman kemasan yang tersedia di Grand Toserba Makassar. Dataset ini mencakup gambar yang diambil langsung menggunakan

kamera smartphone Xiaomi 13T dengan resolusi 3072×4096 piksel, aperture f/1.9, dan nilai ISO yang bervariasi secara acak antara 490 hingga 600. Pengamatan lapangan memastikan keragaman kategori produk sehingga data yang dikumpulkan representatif. Kumpulan data ini menjadi dasar untuk melatih model dalam mendeteksi informasi nutrisi dan memprediksi dampaknya terhadap kesehatan. Gambar 2a menunjukkan contoh gambar label nutrisi yang diperoleh sebelum proses seleksi.

2.2. Pemilihan data dan augmentasi data

Sebelum memasuki tahap pelatihan model, para peneliti melakukan seleksi awal terhadap seluruh kumpulan gambar. Mereka mengesampingkan gambar yang terlalu buram atau kehilangan fokus secara signifikan akibat getaran kamera atau jarak pengambilan gambar yang tidak ideal. Seleksi ini memastikan hanya gambar dengan detail teks yang terbaca yang dilanjutkan ke tahap berikutnya, sehingga menghindari noise yang dapat mengganggu proses pelatihan model.

Setelah tahap penyaringan, para peneliti melakukan augmentasi dengan mengurangi tingkat kecerahan untuk mensimulasikan kondisi pencahayaan redup yang umum ditemukan di lingkungan ritel. Dengan memperluas distribusi kecerahan, mereka melatih model untuk mengenali label nutrisi bahkan dalam kondisi pencahayaan yang kurang optimal. Teknik ini juga mengurangi risiko overfitting karena jaringan saraf tidak hanya fokus pada pola pencahayaan spesifik data asli tetapi juga beradaptasi dengan variasi kontras yang lebih luas. Akibatnya, model menjadi lebih tangguh dan mampu generalisasi saat dihadapkan pada data baru. Gambar 2 menggambarkan kondisi berbeda sebelum dan setelah augmentasi, menunjukkan label nutrisi dalam pencahayaan normal (a) dan hasil pengurangan kecerahan (b).



(a) Gambar Asli




(b) Gambar Setelah Augmentasi

Fig. 2 Label Nutrisi pada Kemasan Minuman dengan asi setelah Proses Pengurangan *Kecerahan*

2.3. Penandaan

Pada tahap penandaan, para peneliti menandai dataset yang telah di-augmentasi untuk mempersiapkannya untuk pelatihan model. Proses ini dilakukan menggunakan Roboflow, platform yang memudahkan penandaan gambar secara presisi. Mereka menandai enam kategori: kalori (0), lemak total (1), lemak jenuh (2), karbohidrat (3), gula (4), dan garam (5). Kategori-kategori ini dipilih berdasarkan pertimbangan kesehatan dasar, karena secara langsung berkontribusi pada risiko penyakit tidak menular (PTM) seperti diabetes, hipertensi, dan penyakit kardiovaskular. Misalnya, asupan kalori berlebihan dapat menyebabkan obesitas dan meningkatkan risiko penyakit jantung dan diabetes. Pada saat yang sama, tingkat lemak jenuh, gula, dan garam yang tinggi erat terkait dengan gangguan metabolik [23].

Meskipun protein penting bagi tubuh, protein tidak menjadi fokus utama studi ini, karena asupan protein biasanya sudah seimbang dalam diet harian dan tidak memiliki dampak langsung pada peningkatan risiko PKT, seperti halnya gula, lemak, dan garam. Para peneliti melakukan penandaan dengan cermat untuk memastikan model dapat mengekstrak informasi secara tepat, meskipun gambar yang digunakan memiliki variasi pencahayaan atau kualitas. Proses ini mempersiapkan data yang ditandai untuk tahap pelatihan model, sehingga meningkatkan akurasi deteksi objek pada gambar label nutrisi. Misalnya, Gambar 3 menunjukkan gambar label nutrisi pada kemasan minuman, dan penandaan menyoroti setiap komponen nutrisi.



Gambar 3: Penandaan s pada Gambar Label Nutrisi Kemasan Minuman

2.4. Klasifikasi YOLOv8

Pada tahap pelatihan model, para peneliti membagi dataset yang telah melalui proses penandaan dan augmentasi menjadi tiga subset: 80% untuk pelatihan (1.931 gambar), 10% untuk validasi (241 gambar), dan 10% untuk pengujian (241 gambar). Strategi pembagian ini bertujuan untuk mencegah overfitting dan memastikan bahwa evaluasi model menggunakan data yang belum pernah dilihat oleh proses pelatihan [24].

Studi ini menggunakan model YOLOv8 (You Only Look Once versi 8) sebagai arsitektur deteksi objek utama. YOLOv8 dipilih karena mencapai keseimbangan optimal antara kecepatan inferensi dan akurasi deteksi, menjadikannya sangat cocok untuk aplikasi praktis [25]. Selain itu, sebagai versi terbaru dalam keluarga YOLO, YOLOv8 secara native mendukung segmentasi instance berbasis poligon melalui kerangka kerja Ultralytics resmi, yang menyediakan output segmentasi langsung melalui struktur data Results.masks [25]. Fungsi ini sangat penting dalam konteks penelitian ini, karena para peneliti membuat anotasi label nutrisi menggunakan metode poligon untuk mengatasi variasi orientasi dan tumpang tindih antara komponen pada label kemasan. Dengan memanfaatkan segmentasi poligon, YOLOv8 dapat mendeteksi dan memisahkan wilayah informasi nutrisi dengan lebih presisi, bahkan dalam kondisi rotasi teks dan tata letak yang tidak seragam.

Untuk memastikan teks nutrisi kecil tetap terbaca meskipun gambar kemasan mengandung noise, studi ini melatih YOLOv8 dengan resolusi input 1024×1024 piksel. Resolusi yang lebih tinggi ini dibandingkan dengan standar 640×640 memungkinkan model menangkap detail spasial huruf dan angka dengan lebih efektif. Pelatihan dilakukan pada perangkat dengan RAM 8 GB dan GPU NVIDIA GTX 1650 (VRAM 4 GB), yang terbukti memadai untuk memproses gambar resolusi

197 tinggi. Tabel 1 mencantumkan semua hiperparameter pelatihan untuk memungkinkan replikasi konfigurasi secara transparan.
198

Tabel 1 Konfigurasi Hiperparameter Pelatihan Model YOLOv8

Hiperparameter	Nilai	Deskripsi
Epoch	100	Jumlah iterasi penuh atas dataset pelatihan
Ukuran Gambar	1024 × 1024 piksel	Resolusi tinggi untuk menangkap teks kecil dan detail halus
Ukuran Batch	4	Jumlah gambar per batch selama pelatihan
Laju Pembelajaran (LR)	0.01	Laju pembelajaran awal untuk stabilitas konvergensi
Optimizer	AdamW	Optimizer adaptif untuk data kompleks dan label yang tidak teratur
Momentum	0.937	Parameter default YOLO untuk mempercepat proses konvergensi
Penurunan bobot	0.0005	Aturan untuk mencegah overfitting

2.5. Ekstraksi fitur menggunakan OCR

Setelah area label nutrisi pada kemasan minuman berhasil terdeteksi dan dipotong menggunakan model YOLOv8, langkah selanjutnya adalah mengekstrak informasi nutrisi dalam bentuk teks. Proses ini dilakukan menggunakan teknologi Pengenalan Karakter Optik (OCR), dengan Tesseract versi 5 (v5) sebagai mesin utama. Tesseract dipilih karena merupakan sistem OCR sumber terbuka yang telah terbukti memiliki kinerja yang andal dalam mengenali teks pada berbagai font dan gaya, termasuk ukuran kecil dan tata letak kompleks yang umum ditemukan pada label kemasan minuman [26]. Salah satu keunggulan utama Tesseract v5 adalah integrasinya dengan jaringan Long Short-Term Memory (LSTM) sebagai arsitektur inti, yang memungkinkan pemrosesan konteks berurutan untuk meningkatkan pengenalan karakter dan angka yang mungkin berisik atau terdistorsi. Dengan memanfaatkan kemampuan LSTM ini, Tesseract v5 secara signifikan meningkatkan akurasi pengenalan, terutama pada label dengan struktur tidak teratur atau orientasi yang kurang optimal [26].

Sebelum Tesseract v5 membaca gambar, gambar label menjalani prapemrosesan umum untuk meningkatkan kontras karakter dan mengurangi noise visual, termasuk konversi ke grayscale, penyesuaian kontras, pengurangan noise, dan segmentasi biner. Setelah OCR menghasilkan teks mentah, proses melakukan langkah pemrosesan pasca singkat: koreksi karakter, penghapusan unit, dan ekstraksi angka, menghasilkan vektor numerik untuk kalori, gula, garam, lemak total, lemak jenuh, dan karbohidrat. Tahap klasifikasi kemudian menggunakan vektor-vektor ini sebagai fitur dalam analisis kesehatan minuman.

2.6. Klasifikasi menggunakan SVM

Tahap berikutnya dari sistem yang dikembangkan melibatkan klasifikasi tingkat kesehatan produk minuman kemasan berdasarkan informasi nutrisi yang diekstraksi. Untuk tujuan ini, studi ini menggunakan algoritma Support Vector Machine (SVM), karena diakui secara luas sebagai metode andal untuk klasifikasi data berdimensi tinggi dan efektif dalam menangani pemisahan kelas linier dan non-linier. SVM mengidentifikasi hiperplane optimal dalam ruang fitur, memungkinkan klasifikasi akurat, terutama ketika batas kelas terdefinisi dengan jelas [27]. Dalam konteks penelitian ini, ruang fitur mewakili kandungan nutrisi yang diekstraksi dari label kemasan minuman. Dengan menerapkan kernel yang sesuai, SVM dapat mengkategorikan minuman ke dalam kategori kesehatan yang telah ditentukan, seperti “aman” atau “tidak aman”, berdasarkan tingkat kandungan nutrisi yang ada.

Fitur yang digunakan untuk klasifikasi meliputi enam komponen nilai gizi utama: kalori, lemak total, lemak jenuh, karbohidrat, gula, dan garam. Ekstraksi teks oleh Tesseract v5 memperoleh informasi numerik ini setelah tahap pra-pemrosesan dan pasca-pemrosesan. OCR kemudian menyimpan data numerik dalam file CSV sehingga peneliti dapat menggunakannya sebagai input terstruktur dalam proses pelatihan dan pengujian model klasifikasi.

Klasifikasi produk sebagai "aman" atau "tidak aman" ditentukan menggunakan pendekatan berbasis aturan dengan nilai ambang batas untuk kandungan nutrisi per porsi. Dalam studi ini, peneliti menetapkan nilai ambang batas kandungan nutrisi pada produk minuman berdasarkan rekomendasi dari Organisasi Kesehatan Dunia (WHO) dan Kementerian Kesehatan Republik Indonesia (Kemenkes RI). Mengingat individu memperoleh asupan nutrisi harian dari berbagai sumber makanan dan minuman, evaluasi risiko kesehatan dalam penelitian ini tidak secara langsung merujuk pada pedoman asupan harian total. Sebaliknya, ambang batas ditetapkan berdasarkan kandungan nutrisi per porsi kemasan untuk menilai kontribusi spesifik setiap produk minuman terhadap risiko kesehatan potensial. Ambang batas ini ditetapkan pada 20-25% dari batas asupan harian yang direkomendasikan sesuai pedoman WHO/Kemenkes, memastikan bahwa satu porsi minuman tidak langsung melebihi ambang batas risiko saat dikonsumsi. Pendekatan ini memberikan penilaian yang lebih relevan terhadap kontribusi produk individu terhadap risiko potensial Penyakit Tidak Menular (PTM).

Sebuah produk akan diklasifikasikan sebagai "tidak aman" jika salah satu atau lebih kandungan nutrisinya melebihi ambang batas per porsi. Sebaliknya, jika semua nilai nutrisi berada di bawah ambang batas, produk tersebut akan dilabeli sebagai "aman". Tabel 2 merangkum ambang batas yang digunakan dalam studi ini.

Tabel 2 Ambang Batas Konsumsi per Porsi

No	Komponen Nutrisi	Ambang Batas per Porsi	Dasar Perhitungan (20-25% dari Batas Harian WHO/Kemenkes)	Catatan Tambahan
1	Kalori	≤ 150 kkal	20% dari ± 2.000 kkal/hari (≈ 400 kkal)	Disesuaikan menjadi 150 kkal, karena minuman tidak dimaksudkan sebagai sumber energi utama, dan kalori dari minuman sering dianggap sebagai kalori kosong.
2	Gula (gula tambahan)	≤ 10 g	20% dari 50 g/hari (≈ 10 g)	Sesuai dengan perhitungan, setara dengan sekitar dua sendok teh gula per porsi.
3	Lemak jenuh	$\leq 1,5$ g	20% dari $\pm 7-8$ g/hari ($\approx 1,5-2$ g)	Batas bawah 1,5 g dipilih untuk keamanan, karena konsumsi lemak jenuh yang berlebihan dapat meningkatkan risiko kardiovaskular.
4	Garam / Natrium	≤ 500 mg	25% dari 2.000 mg/hari (≈ 500 mg)	Sesuai dengan perhitungan, karena minuman jarang melebihi batas ini.

Model SVM didasarkan pada beberapa parameter penting, termasuk jenis kernel (linear, RBF, polinomial), parameter penalti C, dan gamma untuk kernel non-linear. Studi ini melakukan pemilihan kombinasi parameter melalui grid search dengan validasi silang lima lipat. Tabel 3 menampilkan rincian konfigurasi hiperparameter yang diuji dalam proses penyetelan.

Tabel 3 Konfigurasi Hiperparameter SVM " "

Parameter	Nilai yang Diuji	Deskripsi
Kernel	'linear', 'rbf', 'poly'	Tiga jenis kernel yang umum digunakan dalam SVM
C	0,1, 1, 10, 15, 20, 25	Parameter penalti untuk margin kesalahan
Gamma	0.1, 0.5, 1, 2, 3, 4	Parameter untuk kernel RBF dan polinomial

2.7. Pemetaan risiko penyakit potensial

Sebagai tambahan dalam proses klasifikasi, sistem juga mencakup fitur risiko penyakit potensial, yang hanya aktif ketika sistem mengklasifikasikan suatu produk sebagai "tidak aman". Fitur ini bertujuan untuk memberikan peringatan dini kepada pengguna tentang risiko kesehatan spesifik yang mungkin timbul akibat konsumsi berlebihan komponen nutrisi tertentu yang melebihi ambang batas.


Prediksi ini menggunakan pendekatan berbasis aturan, yang menghubungkan komponen nutrisi tertentu dengan risiko penyakit berdasarkan literatur klinis dan rekomendasi dari lembaga kesehatan resmi seperti WHO. Jika sistem mendeteksi

bahwa satu atau lebih komponen, seperti gula, garam, lemak jenuh, atau kalori, melebihi ambang batas, sistem akan secara otomatis menghasilkan peringatan risiko yang relevan dengan komponen tersebut. Misalnya, jika gula terdeteksi melebihi batas yang direkomendasikan ($>10g$), sistem akan menghasilkan peringatan risiko untuk diabetes tipe 2 dan obesitas. Jika natrium (garam) melebihi ambang batas ($>500\text{ mg}$), sistem akan menghasilkan peringatan risiko untuk hipertensi dan penyakit jantung. Sistem juga memungkinkan lebih dari satu peringatan ditampilkan jika beberapa komponen nutrisi terdeteksi dalam kategori berlebihan secara bersamaan. Tabel 4 menunjukkan pemetaan lengkap komponen nutrisi ke risiko penyakit.

Tabel 4 Penyakit potensial berdasarkan komponen kelebihan nutrisi

Komponen Overnutrisi	Risiko Penyakit yang Diprediksi	Referensi
Gula	Diabetes tipe 2, obesitas, penyakit jantung, kerusakan gigi	[23]
Garam (Natrium)	Hipertensi, penyakit jantung, stroke, penyakit ginjal, osteoporosis, kanker lambung	[28]
Lemak jenuh	Kolesterol tinggi, penyakit jantung koroner, stroke, obesitas, diabetes tipe 2, kanker (usus besar, rektum, prostat)	[23]
Kalori	Obesitas, diabetes tipe 2, penyakit jantung, hipertensi, penyakit ginjal, penyakit hati, sindrom metabolik	[29]

Struktur keseluruhan sistem klasifikasi kesehatan produk minuman kemasan ditampilkan pada Gambar 4. Sistem ini terdiri dari lima modul utama yang bekerja secara berurutan. Proses dimulai pada modul pertama (Proses Deteksi), di mana area label nutrisi pada gambar kemasan dideteksi dan dipotong menggunakan model YOLOv8. Selanjutnya, pada modul kedua (Proses Ekstraksi Teks), gambar yang dipotong menjalani prapemrosesan, pembacaan teks dengan OCR Tesseract v5, dan pascapemrosesan untuk mengekstrak angka nutrisi yang bersih. Modul ketiga (Proses Klasifikasi) menggunakan nilai nutrisi yang diekstraksi sebagai masukan untuk algoritma SVM guna menentukan status kesehatan produk, yaitu “aman” atau “tidak aman”. Pada modul keempat (Hasil Deteksi), sistem mengidentifikasi komponen nutrisi yang melebihi ambang batas dan memetakan risiko penyakit potensial yang mungkin timbul. Akhirnya, modul kelima (Presentasi Output) menampilkan hasil akhir dalam bentuk status klasifikasi beserta peringatan risiko atau notifikasi kesalahan jika proses sebelumnya gagal. Struktur modular ini memungkinkan sistem untuk diotomatisasi, transparan, dan andal dalam memberikan evaluasi nutrisi berbasis visual.




Gambar 4 Arsitektur umum sistem klasifikasi kesehatan produk minuman kemasan

3. Hasil dan Pembahasan

Bagian ini menyajikan temuan utama sistem yang dikembangkan secara berurutan. Pertama, studi menjelaskan kinerja YOLOv8 dalam mendeteksi area label nutrisi pada kemasan minuman, kemudian menyajikan akurasi Tesseract v5 dalam


mengekstrak nilai nutrisi. Selanjutnya, kemampuan algoritma SVM untuk mengkategorikan produk ke dalam kategori "aman" dan "tidak aman" dijelaskan, beserta pemetaan risiko penyakit yang timbul saat kandungan nutrisi melebihi ambang batas per porsi. Semua hasil didukung oleh tabel metrik dan visualisasi output sampel, memungkinkan pembaca untuk mengikuti proses dari gambar mentah hingga rekomendasi kesehatan yang dihasilkan.

Temuan pertama berkaitan dengan kinerja model YOLOv8 dalam mendeteksi area label informasi nutrisi. Setelah proses pelatihan, studi mengevaluasi kinerja model menggunakan kurva presisi-pengingat untuk setiap komponen nutrisi. Gambar 5 menyajikan ringkasan kinerja deteksi ini, menampilkan kurva-kurva tersebut untuk setiap kategori label.



Gambar 5 Hasil Kurva Presisi-Kepercayaan

Gambar 5 menampilkan kurva presisi-recall untuk mengevaluasi seberapa baik model YOLOv8 mendeteksi area label informasi nutrisi pada 241 gambar uji, yang mencakup berbagai kondisi pencahayaan dan variasi ukuran teks. Hasil menunjukkan bahwa meskipun model berhasil mengenali hampir semua label (recall mendekati 1), nilai presisi untuk semua kategori tetap tinggi mendekati 0.99. Hasil ini berarti kesalahan dalam mengenali area yang tidak terlabel sangat kecil. Ketika recall mulai menurun, komponen lemak jenuh masih menunjukkan presisi tertinggi sebesar 0.983, diikuti oleh garam (0.976) dan kalori (0.970). Gula dan lemak total mencatat presisi sebesar 0.966 dan 0.960, masing-masing, sedikit lebih rendah, kemungkinan disebabkan oleh ukuran font yang kecil. Sementara itu, karbohidrat merupakan kategori paling sulit untuk dideteksi, meskipun masih mencatat presisi yang cukup baik sebesar 0.957. Secara keseluruhan, nilai mAP pada ambang batas IoU 0.5 mencapai 0.969, dan mAP pada rentang IoU 0.5 hingga 0.95 sebesar 0.73, menunjukkan bahwa model cukup stabil untuk tingkat kedekatan prediksi yang berbeda terhadap area label sebenarnya. Untuk memahami lebih lanjut akurasi prediksi model dalam mengenali setiap komponen nutrisi secara individual, Gambar 6 menampilkan distribusi kesalahan klasifikasi antara label dalam bentuk matriks kebingungan yang dinormalisasi.



Gambar 6 Matriks Kebingungan

Gambar 6 menampilkan matriks kebingungan yang dinormalisasi, yang menunjukkan seberapa akurat model dalam mengenali enam komponen label nutrisi, serta latar belakang. Nilai pada diagonal utama, yang berkisar antara 0,98 hingga 0,99, menunjukkan bahwa sebagian besar komponen, seperti garam, gula, kalori, karbohidrat, lemak total, dan lemak jenuh, terdeteksi dengan sangat akurat. Namun, masih ada proporsi kecil kesalahan klasifikasi. Latar belakang salah dikenali sebagai salah satu komponen nutrisi, yaitu garam (2%), karbohidrat (2%), lemak total (2%), gula (1%), kalori (1%), dan lemak jenuh (1%). Selain itu, model juga salah mengklasifikasikan sekitar 1% area lemak total sebagai kalori. Kesalahan ini mungkin dipicu oleh kemasan dengan pola visual yang mirip label, ukuran teks yang kecil, atau jarak baris yang terlalu rapat, sehingga sulit bagi model untuk membedakan batas antara komponen. Meskipun ada beberapa kesalahan klasifikasi, tidak ada kasus di mana model sering kali salah mengidentifikasi komponen nutrisi. Secara keseluruhan, tingkat kesalahan masih relatif kecil dan tidak mengganggu kinerja sistem dalam konteks penggunaan nyata. Visualisasi lebih lanjut hasil deteksi komponen nutrisi oleh model pada gambar nyata ditampilkan pada Gambar 7 di bawah ini.



Gambar 7 Hasil Deteksi YOLOv8

Gambar 7 menunjukkan hasil deteksi pada salah satu gambar uji acak, di mana model berhasil mengenali enam komponen nutrisi menggunakan poligon berwarna berbeda dan tingkat kepercayaan di atas 0,84. Karbohidrat dan gula, yang merupakan dua komponen dengan ukuran teks relatif kecil, masing-masing dideteksi dengan presisi 0,84, sementara komponen lainnya berada dalam rentang 0,86 hingga 0,89. Kinerja deteksi yang kuat pada kemasan karton ini menunjukkan potensi model dalam kondisi ideal. Namun, untuk menguji ketahanan sistem dalam situasi yang lebih menantang, kami melanjutkan pengujian pada kemasan silinder. Gambar 8 di bawah ini menunjukkan salah satu contoh di mana model tidak berhasil mendeteksi semua komponen nutrisi secara lengkap.



Fig. 8 Hasil Deteksi yang Tidak Lengkap

Gambar 8 menunjukkan contoh deteksi pada botol silinder, yang dalam kasus ini berhasil mendeteksi lemak total, lemak jenuh, karbohidrat, dan gula, tetapi gagal mengenali kalori dan garam, meskipun label mencantumkan keduanya. Kegagalan ini terutama disebabkan oleh kelengkungan botol yang merusak tampilan garis teks, menyebabkan beberapa karakter keluar dari bidang fokus kamera dan mengganggu pembentukan poligon deteksi. Karena deteksi sangat bergantung pada batas kontras dan kontinuitas tepi, distorsi ini memecah fitur visual. Hal ini menurunkan skor kepercayaan di bawah ambang batas 0,30,

sehingga mekanisme penekanan non-maksimum menghilangkan prediksi. Contoh ini menyoroti batasan kinerja model saat menangani kemasan melengkung dan menunjukkan pentingnya menambahkan berbagai bentuk wadah ke data pelatihan. Berdasarkan temuan ini, pembahasan selanjutnya berfokus pada tahap prapemrosesan gambar, yang bertujuan untuk mempersiapkan potongan label agar dapat dikenali secara optimal oleh Tesseract v5. Gambar 9 menunjukkan proses ini secara bertahap.




Fig. 9 Tahapan Prapemrosesan

Setiap bagian dari gambar yang dideteksi oleh YOLOv8 melewati enam tahap prapemrosesan sebelum diproses oleh mesin OCR. Tahap pertama melibatkan konversi gambar RGB menjadi gambar grayscale, sehingga mengurangi dimensi warna. Selanjutnya, intensitas piksel dinormalisasi ke rentang 0-255 menggunakan fungsi `cv2.normalize` untuk meratakan kontras antara area terang dan gelap. Tahap ketiga menerapkan blur Gaussian dengan kernel 3×3 untuk mengurangi noise halus yang dapat mengganggu segmentasi huruf. Proses dilanjutkan dengan binarisasi menggunakan nilai ambang tetap 100 dan mode `THRESH_BINARY_INV`, sehingga teks putih muncul dengan jelas di latar belakang hitam. Setelah itu, dilatasi morfologis dengan kernel 2×2 untuk satu iterasi diterapkan untuk menutup celah tipis pada garis huruf. Tahap akhir membalik warna gambar (`bitwise_not`) sehingga teks muncul hitam pada latar belakang putih, sesuai persyaratan input Tesseract. Gambar 9 menunjukkan semua langkah ini.

Setelah gambar siap, sistem menggunakan Tesseract v5 untuk melakukan pembacaan karakter dengan konfigurasi OEM 3, PSM 7, dan paket bahasa `ind+eng`. Hasil awal OCR dalam bentuk string mentah seringkali mengandung kesalahan, seperti angka "0" dibaca sebagai huruf "O", kemunculan karakter asing seperti tanda seru di belakang angka, campuran koma dan titik dalam angka desimal, serta duplikasi angka akibat pantulan cahaya. Untuk mengatasi masalah ini, sistem menerapkan pembersihan teks otomatis dalam beberapa tahap. Proses dimulai dengan ekstraksi bagian numerik menggunakan ekspresi reguler untuk menghapus satuan dan simbol. Selanjutnya, sistem menstandarkan notasi desimal dengan mengganti koma dengan titik. Sistem kemudian memvalidasi angka yang diperoleh terhadap batas konsumsi logis, seperti kalori tidak melebihi 1000 kcal, lemak total di bawah 100 gram, dan natrium tidak lebih dari 500 mg, untuk menyaring nilai outlier yang tidak realistis. Sebagai langkah akhir, sistem merangkum angka-angka tersebut ke dalam format bulat atau desimal satu digit sesuai dengan kebutuhan klasifikasi. Gambar 10 menggambarkan seluruh proses ini.

Cropped Image		Raw OCR Output	Post-Processing Output
Energi Total 110		Energi Total 110	110.0
Lemak Total	0	Lemak Total 0	0.0
Lemak Jenuh	0	Lemak Jenuh 0!	0.0
Karbohidrat Total	25	Karbohidrat Total 25	25.0
Gula	20	Gula 20	20.0
Garam (Natrium)	85	Garam (Natrium) 85	85.0
(a)		(b)	(c)

Gambar 10 Tahap Pemrosesan Pasca-Pemindaian

Gambar 10 menampilkan hasil dari tiga tahap utama dalam proses pembacaan nilai gizi: (a) potongan gambar yang terdeteksi oleh YOLOv8, (b) pembacaan awal oleh Tesseract OCR, dan (c) output akhir setelah pasca-pemrosesan. Pada baris pertama, “Total Energy 110” dikenali dengan benar dan hanya memerlukan penyesuaian format menjadi “110.0”. Selain itu, “Total Lemak 0” juga dibaca dengan akurat dan diformat ulang menjadi “0.0”. Dalam kasus “Lemak Jenuh 0!”, tahap pasca-pemrosesan berhasil menghapus karakter asing berupa tanda seru (!). Tiga komponen lainnya, yaitu “Total Karbohidrat 25”, “Gula 20”, dan “Garam (Natrium) 85”, dibaca dengan benar oleh OCR dan hanya memerlukan pemisahan angka dari teks serta penyesuaian format numerik menjadi “25.0”, “20.0”, dan “85.0”. Hasil ini menunjukkan bahwa kombinasi prapemrosesan dan pascapemrosesan dapat secara signifikan meningkatkan akurasi hasil pembacaan teks. Untuk memberikan gambaran kuantitatif tentang dampak prapemrosesan terhadap kinerja OCR, studi ini menguji tiga sampel gambar dalam kondisi visual yang berbeda. Tabel 5 menampilkan perbandingan tingkat kesalahan pembacaan sebelum dan setelah prapemrosesan.

Tabel 5 Dampak Pra-pemrosesan terhadap Akurasi OCR dalam Berbagai Kondisi Gambar

Gambar	WER			CER		
	WER Tanpa Pra-pemrosesan	WER dengan Pra-pemrosesan (Metode yang Diusulkan)	Δ WER	CER Tanpa Pra-pemrosesan	CER dengan Pre-proc (Metode yang diusulkan)	Δ CER
Sample_1.jpg	0,055556	0	-0,055556	0,015152	0	-0,01515
sample_2.jpg	0,166667	0	-0,16667	0,144444	0	-0,14444
sample_3.jpg	1,416667	0,833333	-0,58333	0,707386	0,551858	-0.15553

Tabel 5 menunjukkan bahwa tahap prapemrosesan gambar secara konsisten mengurangi tingkat kesalahan pembacaan teks oleh OCR. Pada sampel_1 dengan pencahayaan ideal, WER berkurang dari 0,056 menjadi 0 dan CER dari 0,015 menjadi 0, menunjukkan bahwa semua kata dan karakter dikenali dengan sempurna setelah prapemrosesan. Peningkatan yang lebih signifikan terlihat pada sampel_2, gambar yang direduplikasi melalui peningkatan kecerahan, di mana WER turun dari 0,167 menjadi 0 dan CER dari 0,144 menjadi 0; normalisasi kontras dan binarisasi terbukti efektif dalam memulihkan keterbacaan


teks meskipun kondisi pencahayaan buruk. Pada sampel_3 botol silinder " ", kesalahan tetap ada tetapi berkurang secara signifikan: WER berkurang sekitar 0,58 poin dan CER sekitar 0,16 poin. Hasil ini menunjukkan bahwa tahap blur, thresholding, dan dilasi mampu mengurangi distorsi yang disebabkan oleh kelengkungan secara parsial, meskipun pantulan plastik masih menimbulkan kesalahan sisa. Secara keseluruhan, prapemrosesan memberikan peningkatan akurasi terbesar pada gambar dengan pencahayaan rendah, diikuti oleh objek melengkung, sementara tetap bermanfaat dalam kondisi ideal.

Setelah angka yang dihasilkan oleh OCR dibersihkan melalui tahap pasca-pemrosesan, seperti yang ditunjukkan pada Gambar 11, studi ini mengorganisir seluruh output menjadi dataset terstruktur dalam format CSV. Dataset ini berisi 2.414 gambar sampel produk minuman kemasan, masing-masing mencakup enam nilai kandungan nutrisi utama: kalori, lemak total, lemak jenuh, karbohidrat, gula, dan garam. Berdasarkan nilai-nilai ini, setiap entri secara manual dilabeli sebagai "aman" atau "tidak aman," merujuk pada ambang batas per porsi yang dirangkum dalam Tabel 2. Penilaian ini tidak bergantung pada kebutuhan harian, melainkan mempertimbangkan kontribusi nutrisi per kemasan proporsional terhadap asupan nutrisi individu.

Langkah awal pemodelan SVM dimulai dengan membagi data menjadi set pelatihan dan pengujian menggunakan pembagian terstratifikasi 80:20 untuk menjaga keseimbangan label. Dari total 2.414 titik data, studi ini menggunakan 1.931 sampel untuk pelatihan dan 483 sampel sisanya untuk pengujian. Namun, analisis awal menunjukkan distribusi kelas yang tidak seimbang: 1.938 sampel (80,41%) diberi label "tidak aman," sedangkan hanya 472 sampel (19,59%) diberi label "aman." Ketidakseimbangan ini berisiko memihak model ke kelas mayoritas. Untuk mengatasi masalah ini, studi ini menerapkan Teknik Oversampling Minoritas Sintetis (SMOTE) pada data pelatihan. SMOTE mensintesis sampel baru dari kelas minoritas dengan menginterpolasi fitur antara tetangga terdekat, sehingga menghasilkan data tambahan yang tidak identik dan memperluas representasi kelas minoritas tanpa meningkatkan risiko overfitting atau mengganggu distribusi data uji [30].

Setelah penyeimbangan kelas, studi menormalisasi semua fitur numerik menggunakan metode z-score untuk menyamakan skala antar fitur, menghasilkan distribusi dengan rata-rata nol dan simpangan baku satu. Normalisasi adalah langkah penting dalam prapemrosesan data karena SVM sangat sensitif terhadap perbedaan skala antar fitur dan bergantung pada perhitungan jarak di ruang fitur; oleh karena itu, penskalaan yang tepat dapat secara signifikan meningkatkan kinerja model [27]. Studi ini kemudian menginisialisasi dan melatih model SVM menggunakan GridSearchCV dengan validasi silang lima lipat. Tabel 3 menampilkan ruang pencarian hiperparameter yang digunakan.

Hasil penyesuaian menunjukkan bahwa kernel RBF dengan parameter $C = 10$ dan $\gamma = 4$ menghasilkan kombinasi terbaik. Model dengan konfigurasi ini digunakan untuk mengklasifikasikan data uji yang belum tersentuh oleh proses oversampling. Evaluasi data uji menghasilkan tingkat akurasi 0,9986, menunjukkan bahwa hampir semua sampel diklasifikasikan dengan benar. Akurasi tinggi ini menunjukkan bahwa fitur numerik dari OCR, setelah prapemrosesan dan pascapemrosesan, cukup representatif untuk membedakan secara efektif antara produk "aman" dan "tidak aman". Untuk melihat kinerja klasifikasi secara keseluruhan, hasil prediksi dibandingkan dengan label aktual melalui matriks kebingungan dan metrik klasifikasi lainnya, seperti yang ditunjukkan pada Gambar 11 dan Tabel 6.



Gambar 11 Matriks Kebingungan Klasifikasi Produk Aman dan Tidak Aman

Tabel 6 Hasil Evaluasi Kinerja Model SVM pada Data Uji

	Presisi	Recall	F1-score
Aman	0.99	1.00	1.00
Tidak aman	1.00	1.00	1.00

Gambar 11 menampilkan matriks kebingungan hasil prediksi model SVM terhadap data uji yang tidak menjalani proses oversampling. Dari total 723 sampel, hanya satu sampel yang diberi label “tidak aman” yang salah diklasifikasikan sebagai “aman”, sementara semua sampel lainnya diklasifikasikan dengan benar. Tingkat akurasi yang sangat tinggi ini didukung oleh Tabel 6, yang merangkum presisi, recall, dan skor F1 untuk setiap kelas. Kategori "tidak aman" mencatat skor sempurna pada ketiga metrik sebesar 1.00, sementara kategori "aman" menunjukkan presisi 0.99 dan recall 1.00, menghasilkan skor F1 sebesar 1.00. Keseimbangan metrik ini menunjukkan bahwa model tidak hanya efektif dalam mengenali produk aman tetapi juga sangat andal dalam mengidentifikasi produk dengan risiko kesehatan.

Sebagai validasi komprehensif alur sistem yang dikembangkan, studi ini melakukan tinjauan visual terhadap tiga produk minuman sampel: dua diklasifikasikan sebagai "tidak aman" dan satu sebagai "aman." Setiap contoh menampilkan output end-to-end sistem, dimulai dengan deteksi label menggunakan YOLOv8, diikuti ekstraksi nilai nutrisi dengan Tesseract v5 OCR, klasifikasi dengan SVM, dan pemetaan risiko penyakit berdasarkan komponen nutrisi yang melebihi ambang batas. Gambar 12(a), 12(b), dan 12(c) menampilkan ketiga contoh, sementara Tabel 7 menampilkan ringkasan output numerik dan status kesehatan mereka. Persyaratan ambang batas nutrisi dan pemetaan risiko penyakit mengikuti pendekatan berbasis aturan yang dijelaskan dalam Tabel 5 pada bagian Metode.

Status: UNSAFE
Excessive: Sugar, Saturated Fat

INFORMASI NILAI GIZI (Nutrition Facts)

Takaran Saji 200 ml (1 Kotak)
 Serving Size 200 mL/6.76 fl. oz (1 Pack)
 1 Sajian per Kemasan
 1 Serving per Container

JUMLAH PER SAJIAN (AMOUNT PER SERVING)
 Energi Total 150 kkal
 Energi dari Lemak 40 kkal
 Energi from Fat 40 kkal

		%AKG/ %DV*
Lemak Total (Total Fat)	4.5 g	7 %
Kolesterol (Cholesterol)	15 mg	4 %
Lemak Jenuh (Saturated Fat)	2.5 g	13 %
Protein	6 g	11 %
Karbohidrat Total (Total Carbohydrate)	22 g	7 %
Gula (Sugars)	19 g	
Garam (Natrium) (Sodium)	50 mg	3 %

Vitamin A 20 % Vitamin B12 20 %
 Vitamin C 8 % Biotin 20 %
 Vitamin D3 15 % Kolin (Choline) 8 %
 Vitamin K 6 % Kalsium (Calcium) 20 %
 Vitamin B1 20 % Seng (Zinc) 6 %
 Vitamin B2 20 % Magnesium 6 %
 Vitamin B3 15 % Fosfor (Phosphorus) 25 %
 Vitamin B5 10 % Selenium 10 %
 Vitamin B6 45 % Kalium (Potassium) 8 %

Komponen Lain (Other component):
 Klorida (Chloride) 190 mg

Health Risks:
 Colon Cancer; Coronary Heart Disease; Dental Caries; Heart Disease; High Cholesterol; Obesity; Prostate Cancer; Rectal Cancer; Stroke; Type 2 Diabetes

(a)

Status: UNSAFE
Excessive: Sugar, Saturated Fat, Calories

RED VELVET POPPING BOBA

INFORMASI NILAI GIZI

Takaran saji 240 mL
 1 Sajian per Kemasan

JUMLAH PER SAJIAN
 Energi total 160 kkal
 Energi dari lemak 35 kkal
 Energi dari lemak jenuh 30 kkal

		%AKG*
Lemak total	3.5 g	5 %
Kolesterol	5 mg	2 %
Lemak trans	0 g	
Lemak jenuh	3 g	16 %
Protein	5 g	8 %
Karbohidrat total	27 g	8 %
Gula	23 g	
Garam (Natrium)	170 mg	11 %

* Persen AKG berdasarkan pada kebutuhan energi 2100 kkal. Kebutuhan energi anda mungkin lebih tinggi atau lebih rendah.

Konsumsi Gula lebih dari 50 gram, Natrium lebih dari 2000 mg/day, atau Lemak total lebih dari 67 gram per orang per hari berisiko hipertensi, stroke, diabetes, dan serangan jantung.

KOMPOSISI: Air, Popping Boba (10%), Gula, Krim Nabati (Mengandung Pewarna Alami Beta-Karoten (E 160B)), Susu Bubuk Full Cream (12%), Glutamat Monosodium (Mengandung Glutamat), Pengemulsi Nabati, Pengawet Asam, Pewarna Alami Karmisin (E 129).

INGREDIENTS: Water, Popping Boba (10%), Sugar, Non-Dairy Creamer (Contains Natural Color Beta-Carotenes (E 160B)), Full Cream Milk Powder (12%), Monosodium Glutamate (Contains Glutamate), Natural Flavors, Salt, Preservatives.

Health Risks:
 Colon Cancer; Coronary Heart Disease; Dental Caries; Heart Disease; High Cholesterol; Hypertension; Kidney Disease; Liver Disease; Metabolic Syndrome; Obesity; Prostate Cancer; Rectal Cancer; Stroke; Type 2 Diabetes

(b)

Status: SAFE
Excessive: None

INFORMASI NILAI GIZI

Takaran saji: 250 ml
 2 Sajian per Kemasan

JUMLAH PER SAJIAN
 Energi Total 35 kkal

		%AKG*
Lemak Total	0 g	0 %
Lemak Jenuh	0 g	0 %
Protein	0 g	0 %
Karbohidrat Total	8 g	3 %
Gula	8 g	
Garam (Natrium)	65 mg	4 %

Vitamin dan mineral:
 Vitamin B1 10 %
 Vitamin B3 20 %
 Vitamin B6 20 %
 Vitamin B12 20 %
 Kalium 35 mg
 Klorida 80 mg

* Persen AKG (Angka Kecukupan Gizi) berdasarkan kebutuhan energi 2750 kkal. Kebutuhan energi anda mungkin lebih tinggi atau lebih rendah.

KONSENTRASI ELEKTROLIT
 Kation mEq/L Anion mEq/L

Health Risks: - Safe -

(c)

Tabel 7 Ringkasan Status Kesehatan yang Diprediksi dan Risiko Penyakit dari Beberapa Produk yang Diuji

Gambar	Status	Komponen Melebihi Batas	Nilai OCR (kcal/g/mg)	Risiko Kesehatan
Gambar 12(a)	Tidak Aman	Gula, Lemak Jenuh	• Energi Total: 150 • Lemak Total: 4,5 • Lemak Jenuh: 2,5 • Karbohidrat: 22 • Gula: 19 • Garam: 50	Diabetes tipe 2; Obesitas; Kerusakan gigi; Penyakit jantung
Gambar 12(b)	Tidak aman	Gula, Lemak jenuh, Kalori	• Kalori: 160 • Lemak total: 3,5 • Lemak jenuh: 3 • Karbohidrat: 27 • Gula: 23 • Garam: 170	Diabetes tipe 2; Hipertensi; Kanker prostat; Kanker rektum; Kanker kolon; Kerusakan gigi; Kolesterol tinggi; Obesitas; Penyakit ginjal; Penyakit hati; Penyakit jantung; Penyakit jantung koroner; Sindrom metabolik; Stroke
Gambar 12(c)	Aman	-	• Kalori: 35 • Lemak total: 0 • Lemak jenuh: 0 • Karbohidrat: 8 • Gula: 8 • Garam: 65	-

Contoh pada Gambar 12(a) menunjukkan produk dengan 19 gram gula dan 2,5 gram lemak jenuh, keduanya melebihi batas yang telah ditentukan. Sistem mengklasifikasikan produk ini sebagai "tidak aman" dan menghasilkan peringatan risiko untuk diabetes tipe 2, obesitas, kerusakan gigi, dan penyakit jantung. Gambar 12(b) mewakili kasus yang lebih kompleks, di mana produk mengandung 23 gram gula, 3 gram lemak jenuh, dan 160 kkal kalori, semua melebihi batas. Akibatnya, sistem memberikan klasifikasi "tidak aman" dan memprediksi berbagai risiko kesehatan, termasuk stroke, penyakit ginjal, kanker (prostat, rektum, dan kolon), sindrom metabolik, kolesterol tinggi, dan beberapa kondisi kardiovaskular. Sebaliknya, Gambar 12(c) menunjukkan minuman dengan semua komponen nutrisi dalam batas yang wajar, sehingga dikategorikan sebagai "aman" tanpa risiko penyakit potensial.

Representasi visual dan numerik ini menunjukkan bagaimana sistem secara konsisten menerapkan logika klasifikasi berbasis aturan dan pembelajaran mesin untuk menghasilkan rekomendasi yang transparan dan dapat ditindaklanjuti oleh pengguna.

4. Kesimpulan

Penelitian ini berhasil mengembangkan sistem deteksi kesehatan minuman kemasan berbasis visi komputer dan kecerdasan buatan melalui lima tahap terintegrasi, yaitu deteksi area label nutrisi dengan segmentasi poligon YOLOv8, ekstraksi teks menggunakan Tesseract v5 OCR dengan pra-pemrosesan dan pasca-pemrosesan, klasifikasi tingkat kesehatan produk dengan SVM yang diseimbangkan SMOTE, dan pemetaan risiko penyakit berdasarkan ambang batas nutrisi per porsi. Kinerja sistem terbukti sangat baik: YOLOv8 mencapai akurasi deteksi (mAP@0.5) sebesar 0.969 (melebihi model serupa yang umumnya berkisar antara 0.92-0.95), Prasunting OCR mengurangi WER dari 1,416 menjadi 0,833 dan CER dari 0,707 menjadi 0,551 pada gambar berkualitas rendah, sementara SVM mencapai akurasi 99,86 persen dengan metrik lengkap, presisi 0,99, recall 0,99, dan f1-score 0,99. Keunggulan utama sistem ini terletak pada integrasi komprehensifnya yang tidak hanya mengekstrak informasi nutrisi tetapi juga menilai kesehatan produk dan secara langsung memetakan risiko penyakit, menjadikannya lebih adaptif dan praktis bagi konsumen dibandingkan pendekatan konvensional. Secara sosial, teknologi ini berpotensi meningkatkan literasi nutrisi masyarakat dan membantu konsumen, terutama generasi muda, membuat keputusan

konsumsi yang lebih sehat, sambil mendukung industri, lembaga pengawasan pangan, dan sektor kesehatan masyarakat dalam analisis cepat produk berisiko tinggi.

Untuk pengembangan masa depan, peneliti dapat memperluas sistem dengan dukungan multibahasa, melatih model pada label yang berorientasi pada kemiringan () untuk meningkatkan ketahanan terhadap rotasi kamera, penyesuaian untuk bentuk kemasan yang lebih kompleks seperti botol transparan atau label melengkung, serta implementasi real-time dalam aplikasi seluler untuk membuat manfaatnya lebih mudah diakses.

Konflik Kepentingan

Para penulis menyatakan tidak ada konflik kepentingan.

Referensi

- [1] I. Sakinah, I. Nurdianty Muhdar, U. Muhammadiyah Hamka Jakarta Jl Peta Barat No, dan J. Barat, "Konsumsi Minuman dan Makanan Kemasan serta Aktivitas Fisik dengan Insidensi Gizi Berlebih pada Remaja di Jakarta," *Nutrire Diaita*, vol. 14, no. 01, hlm. 8-14, 2022.
- [2] N. Andarwulan dkk., "Polanya konsumsi makanan dan asupan gula, garam, dan lemak di Kota Jakarta Selatan-Indonesia," *Nutrients*, vol. 13, no. 4, Apr. 2021.
- [3] E. Shabrina, D. Briawan, I. Ekayanti, dan W. Riyadina, "Perubahan asupan gula, garam, dan lemak pada dewasa obesitas: studi kohort," *Indonesian Journal of Nutrition and Dietetics*, vol. 10, no. 3, hlm. 109, Des. 2022.
- [4] S. Sari, D. Utari, dan T. Sudiarti, "Konsumsi minuman manis kemasan di kalangan remaja," *Ilmu Gizi Indonesia*, vol. 5, no. 1, hlm. 91-100, 2021.
- [5] H. Yuningrum, H. Trisnowati, dan N. Rosdewi, "Faktor risiko penyakit tidak menular (PTM) pada remaja: studi kasus di sekolah menengah negeri dan swasta di Kota Yogyakarta," *Jurnal Formil (Forum Ilmiah) Kesmas Respati*, vol. 6, no. 1, hlm. 41-50, 2021.
- [6] FAO, IFAD, UNICEF, WFP, dan WHO, *Keadaan Keamanan Pangan dan Gizi di Dunia 2024*. Roma, Italia: FAO; IFAD; UNICEF; WFP; WHO, 2024.
- [7] Kementerian Kesehatan Republik Indonesia, "Bahaya Konsumsi Gula Berlebihan: Dampak dan Cara Mencegahnya," 2024. Diakses: 24 Mar. 2025. [Online]. Tersedia: <https://ayosehat.kemkes.go.id/bahaya-konsumsi-gula-berlebihan>
- [8] Badan Kebijakan Pengembangan Kesehatan, "Hasil Utama IHS 2023," 2023. Diakses: 24 Maret 2025. [Online]. Tersedia: <https://www.badankebijakan.kemkes.go.id/daftar-frequently-asked-question-seputar-hasil-utama-ski-2023/hasil-utama-ski-2023/>
- [9] L. Gong dkk., "Metode Jaringan Saraf Dalam Terpadu Baru untuk Pengenalan Tanggal Kedaluwarsa pada Gambar Kemasan Makanan Ritel," *Signal Image Video Process*, vol. 15, no. 3, hlm. 449-457, April 2021.
- [10] A. C. Seker dan S. C. Ahn, "Kerangka kerja umum untuk pengenalan tanggal kadaluwarsa pada kemasan produk menggunakan jaringan konvolusional penuh," *Expert Syst Appl*, vol. 203, Oktober 2022.
- [11] [Q. Thames dkk., "Nutrition5k: Menuju Pemahaman Nutrisi Otomatis pada Makanan Generik," Konferensi IEEE/CVF tentang Penglihatan Komputer dan Pengenalan Pola (CVPR) 2021, hlm. 8899-8907, 2021.
- [12] [M. Ahmed, A. Schermel, J. Lee, M. Weippert, B. Franco-Arellano, dan M. L'Abbé, "Pengembangan Program Informasi Label Makanan: Basis Data Komposisi Makanan Bermerk Kanada yang Komprehensif," *Front Nutr*, vol. 8, Feb. 2022.
- [13] J. Zheng, J. Li, Z. Ding, L. Kong, dan Q. Chen, "Pengenalan Tanggal Kadaluwarsa pada Kemasan Makanan Berbasis DBNet yang Ditingkatkan," *Conn Sci*, vol. 35, no. 1, hlm. 1-16, 2023.
- [14] A. Chaitanya, J. Shetty, dan P. Chiplunkar, "Klasifikasi Gambar Makanan dan Ekstraksi Data Menggunakan Jaringan Saraf Konvolusional dan Web Crawler," dalam *Procedia Computer Science*, Elsevier B.V., hlm. 143-152, 2022.
- [15] J. W. Park, Y. H. Cho, M. K. Park, dan Y. D. Kim, "Uji Kelayakan Pengguna Platform Pertanyaan Keamanan Pangan Mobile Berbasis Pengenalan Gambar," *Sustainability (Swiss)*, vol. 16, no. 21, November 2024.
- [16] M. Han, J. Chen, dan Z. Zhou, "NutrifyAI: Sistem Berbasis AI untuk Deteksi Makanan Real-Time, Analisis Nutrisi, dan Rekomendasi Makanan Personalized," *Computer Vision and Pattern Recognition*, Agustus 2024.
- [17] S. Guru dkk., "Edisi 3 Dipak Vyavahare (2024) Implementasi Penilaian Dampak Kesehatan Makanan Kemasan Melalui Pengenalan Label Nutrisi Menggunakan OCR," *Frontiers in Health Informatics*, vol. 13, no. 3, hlm. 4783-4793, 2024.

- [18] R. Borade, A. Gupta, A. Kathpalia, T. Jain, dan P. Chakurkar, "Model Pembelajaran Mesin untuk Deteksi Alergen Makanan Berbasis Pengenalan Karakter Optik dengan Sistem Rekomendasi untuk Makanan Alternatif," Artikel Penelitian Asli Jurnal Internasional Sistem Cerdas dan Aplikasi dalam Teknik IJISAE, vol. 2024, no. 21s, hlm. 1869-1875, 2024.
- [19] S. Tarannum, M. S. Jalal, dan M. N. Huda, "HALALCheck: Pendekatan Multifaset untuk Pengenalan dan Analisis Makanan Kemasan Halal yang Cerdas," IEEE Access, vol. 12, hlm. 28462-28474, 2024.
- [20] D. Kim, S. Y. Kim, R. Yoo, J. Choo, dan H. Yang, "Metode AI Inovatif untuk Pemantauan Informasi Kemasan Depan: Studi Kasus pada Makanan Bayi," PLoS One, vol. 19, no. 5 Mei, Mei 2024.
- [21] H. Seitaj dan V. Elangovan, "Ekstraksi Informasi dari Label Produk: Pendekatan Penglihatan Mesin," International Journal of Artificial Intelligence & Applications, vol. 15, no. 2, hlm. 57-76, Juli 2024.
- [22] S. Bhatlawande, S. Shilaskar, dan A. Surana, "Sistem pemindai cerdas untuk klasifikasi bahan dan identifikasi komposisi nutrisi pada produk makanan kemasan," Journal of Integrated Science and Technology, vol. 13, no. 1, 2025.
- [23] Organisasi Kesehatan Dunia (WHO), "Diet Sehat," April 2020. Diakses: 6 Mei 2025. [Online]. Tersedia: <https://www.who.int/news-room/fact-sheets/detail/healthy-diet>.
- [24] M. Sivakumar, S. Parthasarathy, dan T. Padmapriya, "Perbandingan antara rasio pelatihan dan pengujian dalam pembelajaran mesin untuk pemrosesan gambar medis," PeerJ Comput Sci, vol. 10, hlm. e2245, September 2024.
- [25] Y. Wu dkk., "YOLOv8-segANDcal: segmentasi, ekstraksi, dan perhitungan fitur akar kedelai," Front Plant Sci, vol. 15, 2024.
- [26] S. Faizullah, M. Sohaib Ayub, T. Alghamdi, T. Syed Ali, M. Asad Khan, dan E. Nabil, "Merevolusi Digitalisasi Dokumen Sejarah: OCR yang Ditingkatkan dengan LSTM untuk Manuskrip Tulis Tangan Arab," IJACSA) International Journal of Advanced Computer Science and Applications, vol. 15, no. 10, hal. 1185-1194, 2024.
- [27] R. Guido, S. Ferrisi, D. Lofaro, dan D. Conforti, "Ringkasan Kemajuan Model Mesin Vektor Dukungan dalam Aplikasi Kesehatan: Sebuah Tinjauan," Information (Swiss), vol. 15, no. 4, April 2024.
- [28] Organisasi Kesehatan Dunia, "Pengurangan Sodium," Februari 2025. Diakses: 6 Mei 2025. [Online]. Tersedia: <https://www.who.int/news-room/fact-sheets/detail/sodium-reduction>
- [29] Organisasi Kesehatan Dunia, "Obesitas dan kelebihan berat badan," Maret 2024. Diakses: 6 Mei 2025. [Online]. Tersedia: <https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight>
- [30] T. Wongvorachan, S. He, dan O. Bulut, "Perbandingan Metode Undersampling, Oversampling, dan SMOTE dalam Mengatasi Klasifikasi Tidak Seimbang pada Penambangan Data Pendidikan," Information (Swiss), vol. 14, no. 1, Januari 2023.



Hak Cipta© oleh para penulis. Lisensi oleh TAETI, Taiwan. Artikel ini merupakan artikel akses terbuka yang didistribusikan sesuai dengan syarat dan ketentuan Lisensi Creative Commons Attribution (CC BY-NC) (<https://creativecommons.org/licenses/by-nc/4.0/>).